

UNIVERSIDAD DEL VALLE DE GUATEMALA
Facultad de Ingeniería

Pipelines en el mundo de los datos

Diego Linares
Andy Fuentes
Christian Echeverria
Diederich Solis

Machine Learning Engineering

Julio 24 de 2026

¿Qué es un pipeline en el mundo de los datos?

La verdad es que la analogía que más nos ayudó a entender el tema fue la que usa IBM en su video Data Pipelines Explained, donde comparan un pipeline de datos con el sistema de agua de una ciudad. Nos gustó mucho porque lo deja bien claro: el agua no llega directo desde el río hasta la llave de tu casa. Primero se recolecta de varias fuentes así como ríos, lagos, pozos, después viaja por tuberías hasta una planta donde se limpia y se purifica, y hasta entonces se distribuye para que la podamos usar sin problema.

Y pues así como en el video lo explica que con los datos pasa algo muy parecido. Los datos crudos salen de un montón de lados: bases de datos, aplicaciones en la nube, sistemas antiguos de la empresa e incluso información que va llegando en tiempo real, que vendría siendo como los ríos que nunca dejan de correr. El punto es que casi nunca sirven tal como llegan. Antes de poder usarlos hay que filtrarlos, limpiarlos y ordenarlos para asegurarnos de que tengan buena calidad. Todo ese recorrido, desde la fuente hasta que el dato llega limpio y listo a su destino, es justamente lo que llamamos un pipeline de datos.

En ese camino pueden entrar en juego varias técnicas que veremos más adelante, como ETL, ELT, la replicación y la virtualización de datos. Y al final del recorrido los datos ya limpios terminan en cosas útiles, como tableros de reportes, un data warehouse de la empresa o un modelo de machine learning.

Un pipeline normalmente cumple con algunas características:

- Es automatizado, o sea que se ejecuta solo, sin que alguien esté haciéndolo a mano, ya sea de forma programada o cuando ocurre algún evento.
- Es repetible y confiable, porque da los mismos resultados cada vez que corre.
- Es escalable, ya que puede manejar cada vez más datos sin quebrarse.
- Se puede monitorear, para darnos cuenta si algo falla y revisar que la calidad se mantenga.

Capas de un data pipeline

Aunque cada implementación es distinta, un pipeline de datos casi siempre se puede separar en varias capas o etapas. Según IBM, los componentes más comunes de un pipeline son la ingesta, el almacenamiento, la transformación, la orquestación, la validación, el monitoreo y los controles de acceso. A grandes rasgos funcionan así:

1. Ingesta: es cuando se capturan los datos desde donde nacen, ya sean bases de datos, APIs, archivos, sensores, logs, etc. Esta captura puede hacerse por lotes (batch) o en flujo continuo (streaming).
2. Procesamiento o transformación: aquí se limpian, se normalizan y se combinan los datos. Se corrigen valores nulos, se estandarizan formatos y se aplican las reglas del negocio. Vendría siendo la planta de tratamiento de la analogía del agua.
3. Almacenamiento: los datos ya procesados se guardan en un destino adecuado, como un data warehouse (para datos ordenados y análisis), un data lake (para datos más crudos) o un lakehouse, que es una mezcla de los dos.

4. Consumo: es la entrega final a quien va a usar los datos, sea un tablero de reportes, una aplicación o un modelo de machine learning.
5. Orquestación y monitoreo: se encarga de coordinar en qué orden se ejecuta todo, manejar reintentos y horarios, y vigilar que el pipeline esté sano. Para esto se usan herramientas como Apache Airflow, Prefect o Dagster.
6. Validación: se revisa que los datos cumplan con lo esperado (formatos correctos, rangos válidos, que no falten campos), para no arrastrar errores hacia las demás etapas.
7. Controles de acceso: se define quién puede ver o usar cada dato, para mantener la seguridad y la privacidad de la información a lo largo del pipeline.




Figura 1. Flujo general de un data pipeline (la orquestación y el monitoreo abarcan todas las etapas).

Procesos para mover y transformar los datos

Siguiendo con la analogía del agua, existen distintas formas de tratar y transportar los datos dentro de un pipeline. Las principales son las siguientes.

ETL (Extract, Transform, Load)

En ETL la transformación ocurre antes de cargar los datos: se extraen de la fuente, se transforman en un espacio intermedio y solo después se cargan ya listos en el destino. Es el enfoque más tradicional y se usa mucho con data warehouses, donde se necesita un esquema definido y datos de buena calidad desde el inicio. Funciona bien cuando hay reglas estrictas o requisitos de cumplimiento, por ejemplo cuando toca anonimizar datos sensibles antes de guardarlos.

ELT (Extract, Load, Transform)

En ELT se cambia el orden: primero se cargan los datos crudos en el destino y la transformación se hace después, ahí mismo. Este enfoque aprovecha la potencia de los data warehouses y data lakes modernos en la nube, como BigQuery, Snowflake o Redshift. Como los datos crudos se cargan de una vez, se gana flexibilidad y rapidez, y las transformaciones se aplican cuando se necesitan. Suele ser la mejor opción cuando se manejan grandes volúmenes de datos. De hecho, IBM menciona que con los data warehouses y lakehouses modernos en la nube, ELT se ha vuelto el enfoque predominante.

Otros procesos: replicación y virtualización de datos

El mismo video de IBM menciona otras técnicas que también aparecen dentro de un pipeline:

- Replicación de datos: consiste en copiar los datos de una fuente hacia uno o varios destinos para mantenerlos sincronizados, normalmente sin transformarlos. Sirve

para tener respaldos o para que varios sistemas trabajen con la misma información actualizada.

- Virtualización de datos: en lugar de mover o copiar los datos físicamente, arma una capa virtual que integra y muestra los datos de varias fuentes como si estuvieran en un solo lugar, consultándolos en su origen cuando hacen falta. Así se evita duplicar información y se tiene una vista unificada casi en tiempo real.

Comparación ETL vs. ELT

Criterio	ETL	ELT
Orden	Extraer, transformar y cargar	Extraer, cargar y transformar
¿Dónde se transforma?	En un espacio intermedio, antes de cargar	En el destino, después de cargar
Tipo de datos	Sobre todo estructurados	Estructurados, semi y no estructurados
Velocidad de ingesta	Más lenta, porque transforma antes	Más rápida, porque carga datos crudos
Destino típico	Data warehouse tradicional	Data lake o warehouse en la nube
Mejor para	Reglas estrictas y calidad previa	Grandes volúmenes y flexibilidad

Modos de procesamiento: por lotes y en tiempo real

Sin importar la técnica, un pipeline puede procesar los datos de dos maneras. La primera es por lotes (batch), donde los datos se juntan y se procesan en grupos en horarios programados, por ejemplo cada noche; funciona bien para grandes cantidades cuando no urge tenerlos al instante. La segunda es en flujo (streaming o tiempo real), donde los datos se procesan de forma continua a medida que van llegando, con muy poca demora; esto es ideal para casos como detección de fraude, monitoreo o recomendaciones en vivo, con herramientas como Apache Kafka o Spark Streaming.

Data pipeline vs. Machine Learning pipeline

Un machine learning pipeline es un tipo especial de pipeline, pero enfocado en construir, entrenar, evaluar y desplegar modelos de aprendizaje automático de forma automatizada y que se pueda repetir sin problemas. Según IBM, una de sus grandes ventajas es que automatiza tareas repetitivas como el preprocesamiento, el feature engineering y la evaluación, lo que ahorra tiempo y reduce errores.

La diferencia principal está en el propósito. Un data pipeline mueve y transforma datos para que se puedan usar en general (análisis, reportes, almacenamiento), mientras que un ML pipeline va un paso más allá y usa esos datos para producir y mantener un modelo

que hace predicciones. De hecho lo normal es que un data pipeline le dé de comer a un ML pipeline: el primero deja los datos listos y el segundo los convierte en un modelo que ya trabaja en producción.

Aspecto	Data pipeline	Machine Learning pipeline
Objetivo	Mover, limpiar y entregar datos	Entrenar y desplegar modelos
Producto final	Datos listos para usar	Modelo entrenado y en producción
Etapas típicas	Ingesta, transformación y carga	Preparación, features, entrenamiento, evaluación y despliegue
Enfoque	Ingeniería de datos	Ingeniería de ML o MLOps
Relación	Le da los datos al ML pipeline	Usa la salida del data pipeline

Etapas de un Machine Learning pipeline

1. Ingesta y recolección de datos: conseguir los datos que sirven para el problema.
2. Preprocesamiento y limpieza: arreglar valores faltantes y atípicos, normalizar y codificar.
3. Ingeniería de características (feature engineering): crear y elegir las variables que mejor representan el problema para el modelo.
4. Entrenamiento del modelo: ajustar el algoritmo con los datos de entrenamiento y buscar los mejores parámetros.
5. Evaluación: medir qué tan bien quedó usando datos de prueba y métricas como exactitud, precisión, recall o F1.
6. Despliegue: poner el modelo a trabajar en producción para que haga predicciones con datos nuevos.
7. Monitoreo y reentrenamiento: vigilar cómo se comporta en producción, detectar si el modelo se empieza a desactualizar y reentrenarlo cuando haga falta.




Figura 2. Etapas de un ML pipeline (el monitoreo puede disparar un nuevo ciclo de reentrenamiento).

Conclusiones

- Al final, un pipeline se parece bastante al sistema de agua de una ciudad: recoge los datos crudos desde la fuente, los limpia y transforma, y los entrega listos en su destino.
- Un data pipeline se puede separar en capas: ingesta, transformación, almacenamiento, consumo y la parte de orquestación y monitoreo.
- Dentro del pipeline pueden convivir varias técnicas, como ETL (transforma antes de cargar), ELT (carga primero y transforma después), y otras como la replicación y la virtualización de datos.
- El data pipeline y el machine learning pipeline se complementan: uno prepara los datos y el otro los convierte en un modelo entrenado y desplegado.
- Separar todo en capas y etapas facilita automatizar, repetir, mantener y escalar los sistemas de datos y de machine learning.

Referencias

- IBM. What is a data pipeline? (incluye el video Data Pipelines Explained). <https://www.ibm.com/think/topics/data-pipeline>
- IBM. What is a machine learning pipeline? <https://www.ibm.com/think/topics/machine-learning-pipeline>
- IBM. What is a data pipeline architecture? <https://www.ibm.com/think/topics/data-pipeline-architecture>
- IBM. What is ETL (Extract, Transform, Load)? <https://www.ibm.com/think/topics/etl>